Checkpoint 1: Stima della Densità di Copula tramite ANN

Copula Gaussiana Bivariata — Caso Noto

Edoardo Caproni, Pietro Pianigiani, Tommaso Quintabà
Corso di Statistical Machine Learning

3 Marzo 2026

1 Obiettivo

L'obiettivo è addestrare una rete neurale (MLP) a stimare la densità di una copula $c(u, v)$ direttamente dai dati, senza assumere una famiglia parametrica. Come primo passo, lavoriamo su un caso con soluzione analitica nota (Copula Gaussiana bivariata, $\rho = 0.7$), così da poter misurare l'errore di stima in modo esatto.

2 Impostazione matematica

2.1 Ground truth (Fasi 1–2)

Consideriamo una Gaussiana Bivariata standard con correlazione ρ:

$$(X, Y) \sim \mathcal{N}\left(\mathbf{0},\ \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}\right)$$

Per il Teorema di Sklar, la densità della copula è definita come:

$$c(u, v) = \frac{f\big(\Phi^{-1}(u),\ \Phi^{-1}(v)\big)}{\varphi\big(\Phi^{-1}(u)\big)\ \varphi\big(\Phi^{-1}(v)\big)}$$

dove Φ è la CDF della normale standard e φ la sua densità. Per la Gaussiana bivariata questa ha forma chiusa:

$$c(u, v) = \frac{1}{\sqrt{1-\rho^2}} \exp\left(-\frac{\rho^2(x^2+y^2) - 2\rho\, x\, y}{2(1-\rho^2)}\right)$$

con $x = \Phi^{-1}(u)$, $y = \Phi^{-1}(v)$. Questa è la nostra verità di riferimento.

2.2 Dataset e marginali (Fase 3)

Generiamo $N = 2000$ campioni (x_i, y_i) dalla distribuzione congiunta. La Figura 1 mostra lo scatter plot dei campioni e le distribuzioni marginali empiriche, sovrapposte alla densità teorica $\mathcal{N}(0, 1)$.

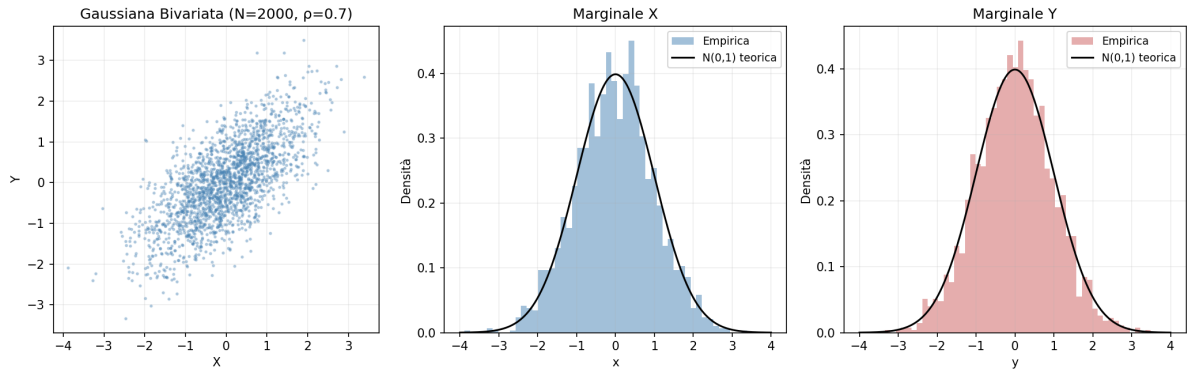

Figure 1: Dataset generato: scatter plot della Gaussiana Bivariata (sinistra) e distribuzioni marginali empiriche vs. teoriche (centro, destra). La correlazione $\rho = 0.7$ è chiaramente visibile nell'allungamento della nuvola di punti lungo la diagonale.

2.3 Pseudo-osservazioni

Poiché nella pratica le CDF marginali non sono note, le stimiamo con la trasformazione dei ranghi:

$$u_i = \frac{\text{rank}(x_i)}{N+1}, \qquad v_i = \frac{\text{rank}(y_i)}{N+1}$$

Il denominatore $N+1$ (anziché N) impedisce valori esattamente pari a 0 o 1, evitando problemi numerici con $\log(0)$ e $\Phi^{-1}(1) = \infty$. La Figura 2 mostra la trasformazione dallo spazio originale al dominio $[0,1]^2$ della copula.

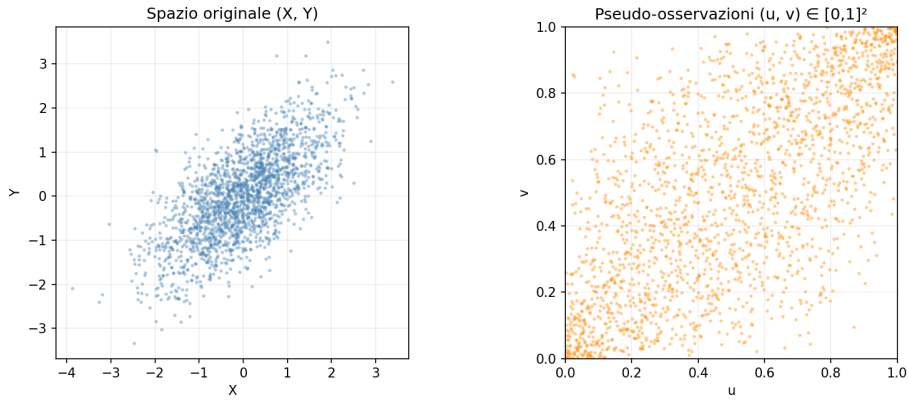

Figure 2: Trasformazione dei ranghi: dallo spazio originale (X, Y) (sinistra) alle pseudo-osservazioni $(u, v) \in [0,1]^2$ (destra). La struttura di dipendenza è preservata.

2.4 Loss function (Fase 4)

La rete $\hat{c}_\theta(u, v)$ prende in input $(u, v) \in [0,1]^2$ e restituisce un valore positivo (garantito dall'attivazione `softplus` sull'ultimo strato). La loss è composta da due termini:

$$\mathcal{L}(\theta) = \underbrace{-\frac{1}{N}\sum_{i=1}^{N} \log \hat{c}_\theta(u_i, v_i)}_{\text{NLL}} + \lambda \underbrace{\left(\iint_{[0,1]^2} \hat{c}_\theta(u, v)\, du\, dv \; - \; 1 \right)^2}_{\text{penalty normalizzazione}}$$

- **NLL**: massimizza la verosimiglianza delle pseudo-osservazioni. È il termine che guida la rete a imparare la *forma* della copula.

- **Penalty**: impone il vincolo $\iint c\,du\,dv = 1$, necessario perché $\hat{c}_\theta$ sia una densità valida. L'integrale è approssimato numericamente su una griglia 50×50 con la regola dei trapezi.

2.5 Metriche di valutazione (Fase 5)

Sulla copula: divergenza di Kullback-Leibler tra densità vera e stimata:

$$D_{\mathrm{KL}}(c \parallel \hat{c}) = \iint_{[0,1]^2} c(u,v) \log \frac{c(u,v)}{\hat{c}_\theta(u,v)}\,du\,dv$$

approssimata su una griglia 200×200, normalizzando entrambe le densità prima del calcolo.

Sulla PDF congiunta ricostruita: verifichiamo che la copula stimata produca una buona ricostruzione della distribuzione congiunta originale tramite il Teorema di Sklar:

$$\hat{f}(x,y) = \hat{c}_\theta\big(\Phi(x),\, \Phi(y)\big) \cdot \varphi(x) \cdot \varphi(y)$$

L'errore L_1 integrato misura la qualità complessiva della ricostruzione.

3 Esperimento 1: Configurazione naive

3.1 Setup

Parametro	Valore
Architettura	MLP: $2 \to 64 \to 64 \to 1$ (`tanh` + `softplus`)
Parametri	4 417
λ	100
Learning rate	10^{-3} (Adam)
Epoche	5 000

3.2 Risultati sulla copula

$$D_{\mathrm{KL}} = 0.0264, \quad \text{errore medio} = 0.147, \quad \iint \hat{c}\,du\,dv \approx 1.005$$

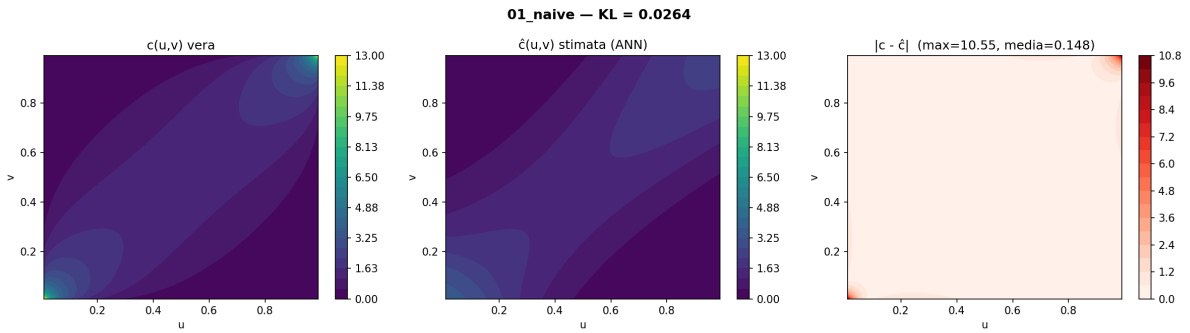

Figure 3: Configurazione naive: confronto contour 2D. La forma qualitativa è catturata, ma la rete fatica a riprodurre i picchi negli angoli $(0,0)$ e $(1,1)$.

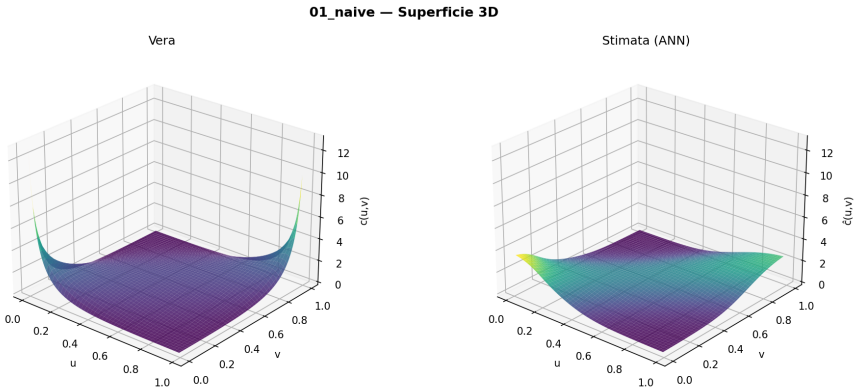

Figure 4: Configurazione naive: superfici 3D. Si nota chiaramente come la rete smussa i picchi che la vera copula presenta agli angoli del dominio.

3.3 Curva di apprendimento

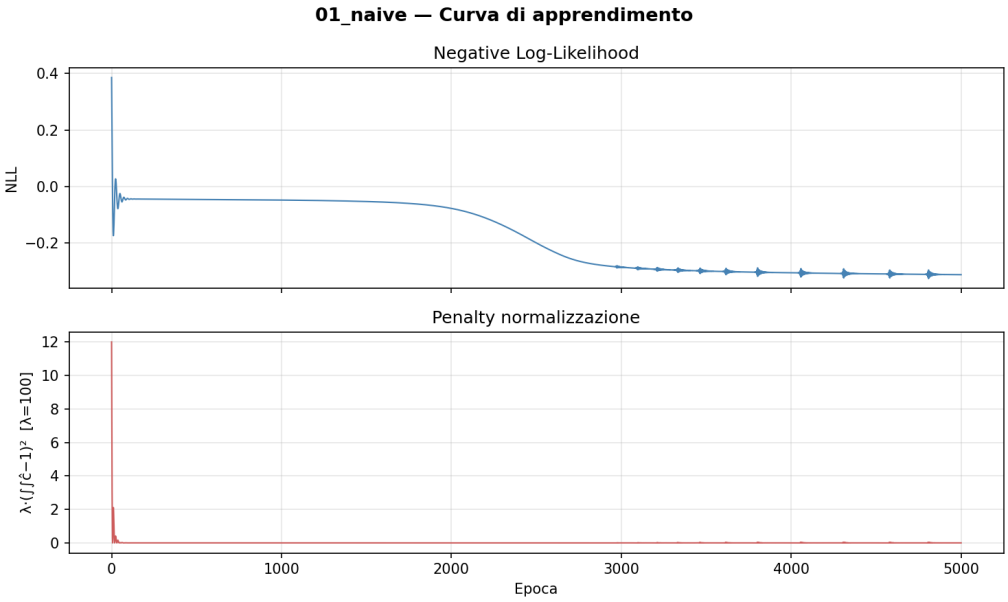

Figure 5: Curva di apprendimento — configurazione naive. La NLL mostra un plateau prolungato (epoche 0–2000): $\lambda = 100$ è troppo forte e penalizza l'esplorazione della forma. Il penalty crolla subito a zero, ma a scapito della NLL.

3.4 Ricostruzione della PDF congiunta

Ricostruiamo la PDF congiunta tramite Sklar: $\hat{f}(x, y) = \hat{c}_\theta(\Phi(x), \Phi(y)) \cdot \varphi(x) \cdot \varphi(y)$.

$$\text{Errore } L_1 \text{ integrato} = 0.169$$

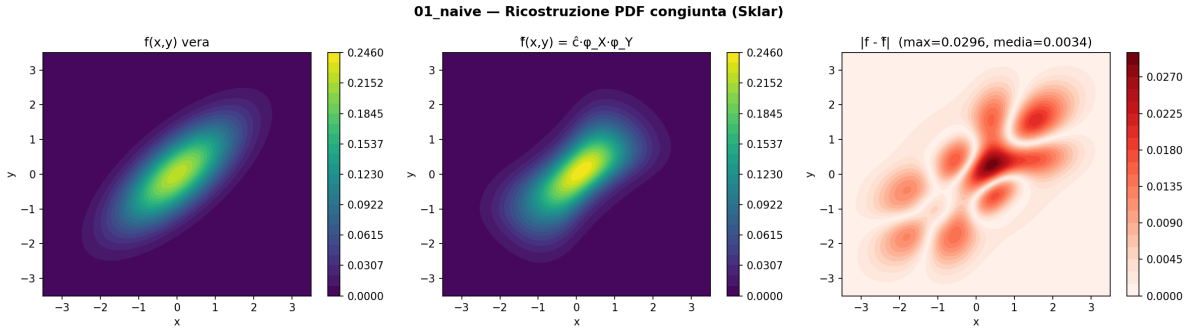

Figure 6: Configurazione naive: ricostruzione della PDF congiunta. Nonostante l'errore sulla copula, la ricostruzione nello spazio originale è qualitativamente buona (errore medio = 0.003). L'errore massimo (0.030) si manifesta nelle code della distribuzione.

4 Grid Search

Per trovare la combinazione migliore di iperparametri, abbiamo eseguito una ricerca esaustiva su 24 configurazioni, tutte addestrate per 5000 epoche sullo stesso dataset ($N = 2000$, seed fissato per riproducibilità).

4.1 Spazio di ricerca

Iperparametro	**Valori testati**	**Ruolo**
Neuroni/strato (*hidden*)	32, 64, 128	Capacità espressiva
Strati nascosti (*layers*)	2, 3	Profondità della rete
λ	10, 100	Peso del vincolo di normalizzazione
Learning rate	10^{-3}, 5×10^{-4}	Velocità di convergenza

4.2 Top 5 risultati

#	**Hidden**	**Layers**	$\boldsymbol{\lambda}$	**LR**	$\boldsymbol{D_{\mathrm{KL}}}$
1	128	3	10	10^{-3}	0.0069
2	64	2	10	10^{-3}	0.0077
3	128	2	10	5×10^{-4}	0.0079
4	64	3	10	10^{-3}	0.0080
5	128	3	10	5×10^{-4}	0.0081

4.3 Analisi

Il risultato più netto è che $\lambda = 10$ **domina sistematicamente** $\lambda = 100$: tutte le top 5 configurazioni usano $\lambda = 10$. L'interpretazione è coerente con l'esperimento naive: un λ troppo alto satura il budget di ottimizzazione sul vincolo di normalizzazione, impedendo alla rete di modellare con precisione la forma della densità.

Il learning rate standard (10^{-3}) risulta sufficiente. La profondità (3 strati) e la larghezza (128 neuroni) aiutano, ma il guadagno rispetto a configurazioni più piccole è modesto.

5 Esperimento 2: Best configuration

5.1 Setup

Parametro	Valore
Architettura	MLP: $2 \to 128 \to 128 \to 128 \to 1$ (`tanh` + `softplus`)
Parametri	33 537
λ	10
Learning rate	10^{-3} (Adam)
Epoche	5 000

5.2 Risultati sulla copula

$$D_{\mathrm{KL}} = 0.0101, \quad \text{errore medio} = 0.154, \quad \iint \hat{c}\, du\, dv \approx 1.047$$

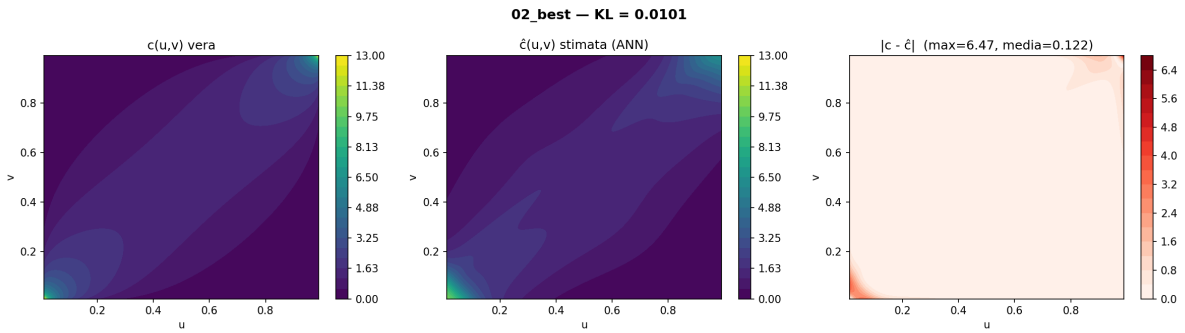

Figure 7: Best configuration: il pattern di errore è concentrato lungo la diagonale concordante, ma il massimo errore è sceso da 10.32 a 4.32 rispetto alla naive.

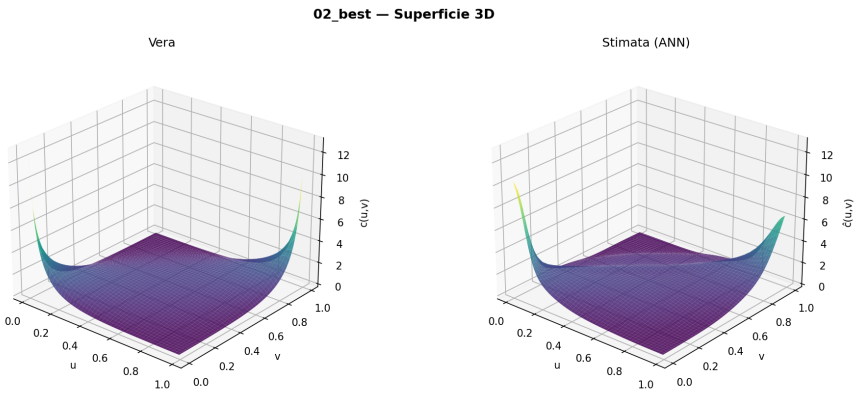

Figure 8: Best configuration: superfici 3D. I picchi agli angoli sono catturati molto meglio rispetto alla configurazione naive (cfr. Fig. 4).

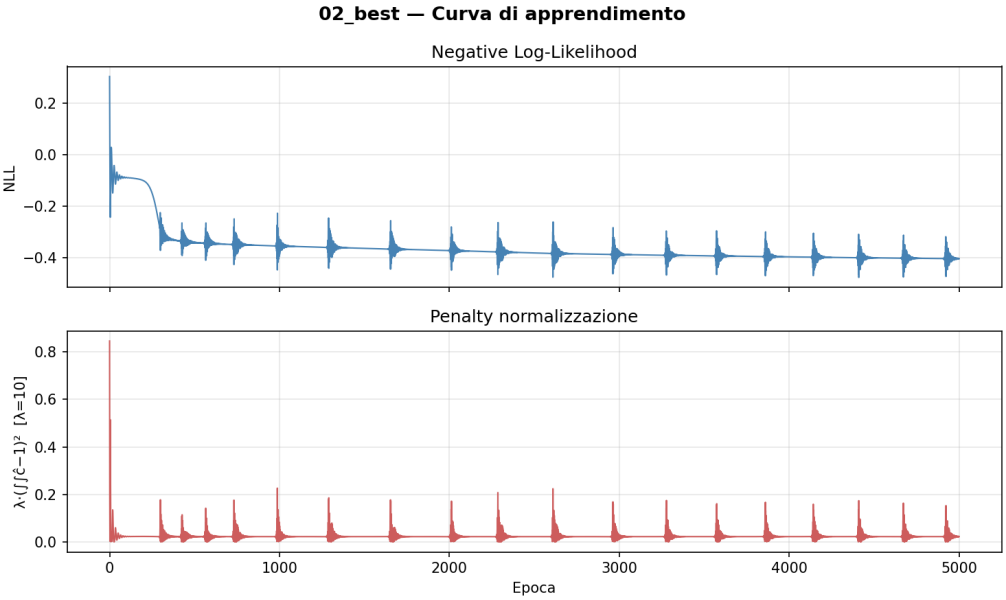

Figure 9: Curva di apprendimento — best configuration. La NLL converge rapidamente (raggiunge -0.35 entro 500 epoche vs. 2500 per la naive) e scende più in basso (-0.40 vs. -0.31). Il penalty oscilla intorno a 0.02, coerente con $\iint \hat{c} \approx 1.047$.

5.3 Ricostruzione della PDF congiunta

$$\text{Errore } L_1 \text{ integrato} = 0.141$$

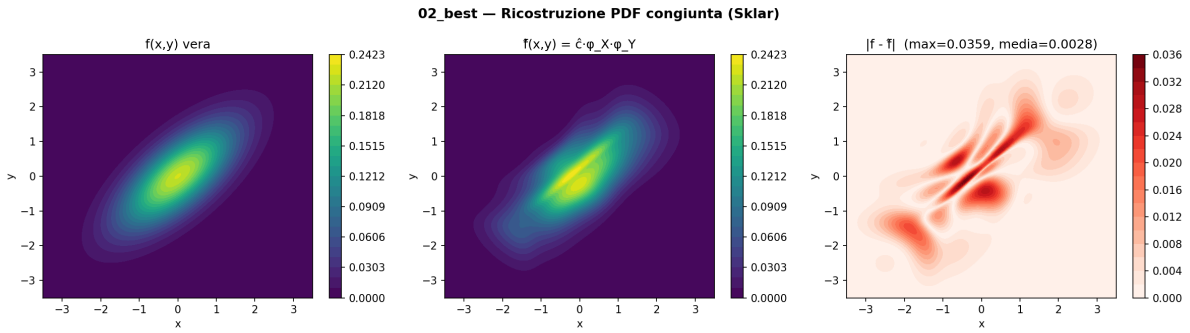

Figure 10: Best configuration: ricostruzione della PDF congiunta. L'errore medio è di appena 0.003 e la ricostruzione è visivamente indistinguibile dall'originale. L'errore residuo (max = 0.036) è concentrato nelle code, dove la densità è comunque molto bassa.

6 Confronto riepilogativo

	D_{KL} (copula)	Errore max (copula)	$\iint \hat{c}$	L_1 (congiunta)
Naive (64×2, $\lambda = 100$)	0.0264	10.32	1.005	0.169
Best (128×3, $\lambda = 10$)	0.0101	4.32	1.047	0.141

La configurazione best migliora su tutte le metriche tranne l'integrale (1.047 vs. 1.005), che resta comunque accettabile. La ricostruzione della PDF congiunta è eccellente per entrambe: anche errori non trascurabili sulla copula (specialmente ai bordi di $[0,1]^2$) si attenuano nello

spazio originale grazie alla moltiplicazione per le densità marginali, che sono molto piccole nelle code.

7 Prossimi passi

1. **Miglioramento sul caso noto:** i picchi agli angoli della copula restano il punto debole. Possibili direzioni: architetture più espressive, scheduling del learning rate, aumento dei campioni.

2. **Copula non banale:** testare su una copula con struttura di dipendenza asimmetrica (es. Clayton, Gumbel).

3. **Dataset reale:** applicare la pipeline a dati reali bivariati dove la vera copula è ignota.

4. **Confronto con baseline:** KDE bivariata e Gaussian Mixture Models.