Checkpoint 1: Stima della Densità di Copula tramite ANN

Copula Gaussiana Bivariata — Caso Noto

Edoardo Caproni, Pietro Pianigiani, Tommaso Quintabà
Corso di Statistical Machine Learning

3 Marzo 2026

1 Obiettivo

L'obiettivo è addestrare una rete neurale (MLP) a stimare la densità di una copula $c(u, v)$ direttamente dai dati, senza assumere una famiglia parametrica. Come primo passo, lavoriamo su un caso con soluzione analitica nota (Copula Gaussiana bivariata, $\rho = 0.7$), così da poter misurare l'errore di stima in modo esatto.

2 Impostazione matematica

2.1 Ground truth (Fasi 1–2)

Consideriamo una Gaussiana Bivariata standard con correlazione ρ:

$$(X, Y) \sim \mathcal{N}\left(\mathbf{0},\ \begin{pmatrix} 1 & \rho \\ \rho & 1 \end{pmatrix}\right)$$

Per il Teorema di Sklar, la densità della copula è definita come:

$$c(u, v) = \frac{f\big(\Phi^{-1}(u),\ \Phi^{-1}(v)\big)}{\varphi\big(\Phi^{-1}(u)\big)\ \varphi\big(\Phi^{-1}(v)\big)}$$

dove Φ è la CDF della normale standard e φ la sua densità. Per la Gaussiana bivariata questa ha forma chiusa:

$$c(u, v) = \frac{1}{\sqrt{1-\rho^2}} \exp\left(-\frac{\rho^2(x^2+y^2) - 2\rho\, x\, y}{2(1-\rho^2)}\right)$$

con $x = \Phi^{-1}(u)$, $y = \Phi^{-1}(v)$. Questa è la nostra verità di riferimento.

2.2 Pseudo-osservazioni (Fase 3)

Generiamo $N = 2000$ campioni (x_i, y_i) dalla distribuzione congiunta. Poiché nella pratica le CDF marginali non sono note, le stimiamo con la trasformazione dei ranghi:

$$u_i = \frac{\mathrm{rank}(x_i)}{N+1}, \qquad v_i = \frac{\mathrm{rank}(y_i)}{N+1}$$

Il denominatore $N+1$ (anziché N) impedisce valori esattamente pari a 0 o 1, evitando problemi numerici con $\log(0)$ e $\Phi^{-1}(1) = \infty$.

2.3 Loss function (Fase 4)

La rete $\hat{c}_\theta(u, v)$ prende in input $(u, v) \in [0, 1]^2$ e restituisce un valore positivo (garantito dall'attivazione `softplus` sull'ultimo strato). La loss è composta da due termini:

$$\mathcal{L}(\theta) = \underbrace{-\frac{1}{N}\sum_{i=1}^{N} \log \hat{c}_\theta(u_i, v_i)}_{\text{NLL}} + \lambda \underbrace{\left(\iint_{[0,1]^2} \hat{c}_\theta(u, v)\, du\, dv \; - \; 1 \right)^2}_{\text{penalty normalizzazione}}$$

- **NLL**: massimizza la verosimiglianza delle pseudo-osservazioni. È il termine che guida la rete a imparare la *forma* della copula.
- **Penalty**: impone il vincolo $\iint c\, du\, dv = 1$, necessario perché $\hat{c}_\theta$ sia una densità valida. L'integrale è approssimato numericamente su una griglia 50×50 con la regola dei trapezi.

2.4 Metrica di valutazione (Fase 5)

Misuriamo la qualità della stima con la divergenza di Kullback-Leibler:

$$D_{\text{KL}}(c \parallel \hat{c}) = \iint_{[0,1]^2} c(u, v) \log \frac{c(u, v)}{\hat{c}_\theta(u, v)}\, du\, dv$$

approssimata numericamente su una griglia 200×200, normalizzando entrambe le densità sulla griglia prima del calcolo.

3 Esperimento 1: Configurazione naive

3.1 Setup

Parametro	**Valore**
Architettura	MLP: $2 \to 64 \to 64 \to 1$ (`tanh` + `softplus`)
Parametri	4 417
λ	100
Learning rate	10^{-3} (Adam)
Epoche	5 000
N campioni	2 000

3.2 Risultati

$$D_{\text{KL}} = 0.0267, \quad \text{errore medio} = 0.147, \quad \iint \hat{c}\, du\, dv \approx 1.005$$

3.3 Osservazioni

- La forma qualitativa della copula è catturata (densità alta lungo la diagonale concordante).
- L'errore è concentrato agli angoli, dove la densità vera diverge: è un limite intrinseco di un MLP con attivazione `softplus`.
- Il valore alto di $\lambda = 100$ forza una normalizzazione quasi perfetta ($\iint \hat{c} \approx 1.005$), ma rallenta drasticamente la discesa della NLL: la rete dedica troppo budget di ottimizzazione al vincolo e poco alla forma.

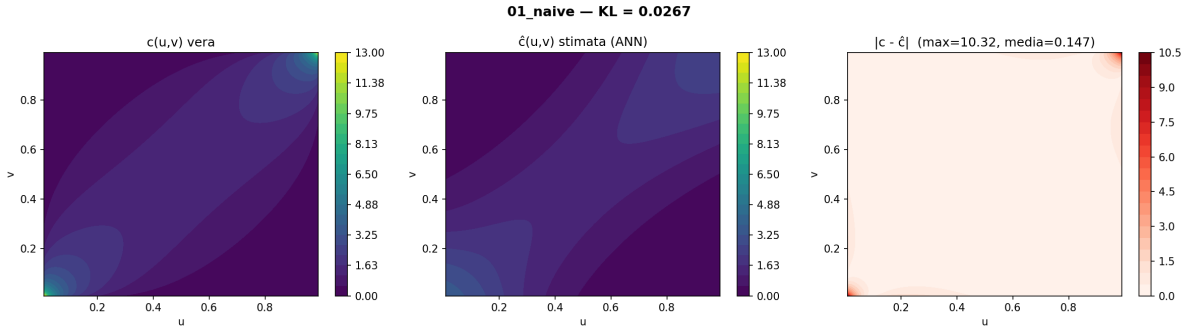

Figure 1: Configurazione naive: confronto tra densità vera (sinistra), stimata (centro) e errore assoluto (destra). La forma qualitativa è catturata, ma la rete fatica a riprodurre i picchi negli angoli $(0, 0)$ e $(1, 1)$.

4 Grid Search

Per trovare la combinazione migliore di iperparametri, abbiamo eseguito una ricerca esaustiva su 24 configurazioni, tutte addestrate per 5000 epoche sullo stesso dataset ($N = 2000$, seed fissato per riproducibilità).

4.1 Spazio di ricerca

Iperparametro	**Valori testati**	**Ruolo**
Neuroni/strato (*hidden*)	32, 64, 128	Capacità espressiva
Strati nascosti (*layers*)	2, 3	Profondità della rete
λ	10, 100	Peso del vincolo di normalizzazione
Learning rate	10^{-3}, 5×10^{-4}	Velocità di convergenza

4.2 Top 5 risultati

#	**Hidden**	**Layers**	$\boldsymbol{\lambda}$	**LR**	$\boldsymbol{D_{\mathrm{KL}}}$
1	128	3	10	10^{-3}	0.0069
2	64	2	10	10^{-3}	0.0077
3	128	2	10	5×10^{-4}	0.0079
4	64	3	10	10^{-3}	0.0080
5	128	3	10	5×10^{-4}	0.0081

4.3 Analisi

Il risultato più netto del grid search è che $\lambda = 10$ **domina sistematicamente** $\lambda = 100$. Tutte le top 5 configurazioni usano $\lambda = 10$. L'interpretazione è coerente con quanto osservato nell'esperimento naive: un λ troppo alto satura il budget di ottimizzazione sul vincolo di normalizzazione, impedendo alla rete di modellare con precisione la forma della densità.

Il learning rate standard (10^{-3}) risulta sufficiente. La profondità (3 strati) e la larghezza (128 neuroni) aiutano, ma il guadagno rispetto a configurazioni più piccole è modesto.

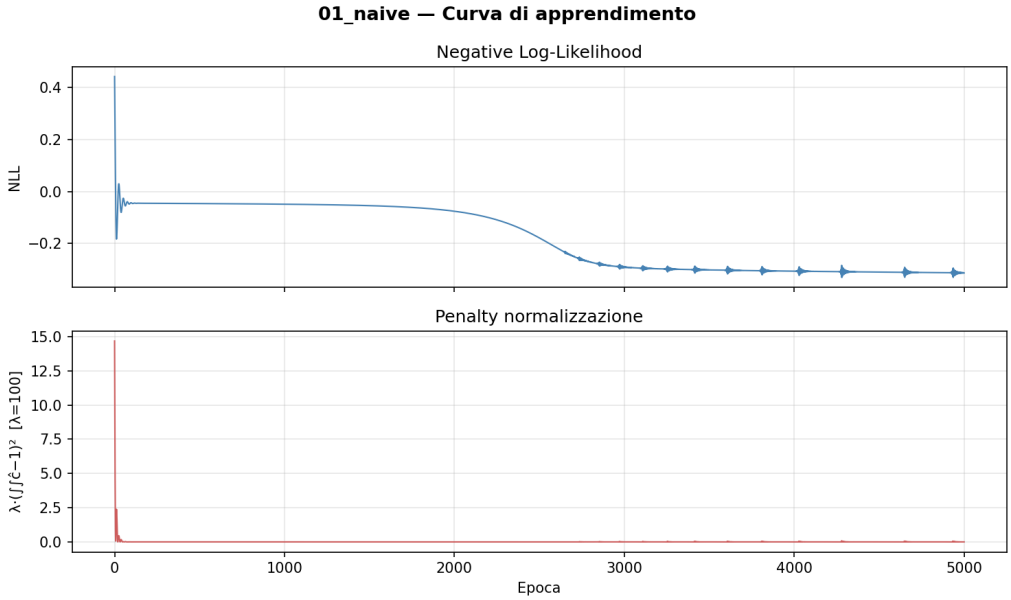

Figure 2: Curva di apprendimento — configurazione naive. In alto: la NLL scende lentamente e mostra un plateau prolungato nelle prime 2000 epoche, indice di un λ troppo forte che penalizza l'esplorazione. In basso: il penalty di normalizzazione crolla rapidamente a zero ($\lambda = 100$ forza $\iint \hat{c} \approx 1$ quasi subito), ma a scapito della capacità della rete di imparare la forma.

5 Esperimento 2: Best configuration

5.1 Setup

Parametro	**Valore**
Architettura	MLP: $2 \to 128 \to 128 \to 128 \to 1$ (`tanh` + `softplus`)
Parametri	33 537
λ	10
Learning rate	10^{-3} (Adam)
Epoche	5 000
N campioni	2 000

5.2 Risultati

$$D_{\mathrm{KL}} = 0.0142, \quad \text{errore medio} = 0.154, \quad \iint \hat{c}\, du\, dv \approx 1.047$$

5.3 Confronto

	D_{KL}	Errore max	$\iint \hat{c}$
Naive (64×2, $\lambda{=}100$)	0.0267	10.32	1.005
Best (128×3, $\lambda{=}10$)	0.0142	4.32	1.047

La configurazione best dimezza quasi la KL divergence e riduce il picco di errore da 10.32 a 4.32. Il compromesso è un integrale leggermente meno preciso (1.047 vs. 1.005), ma accettabile.

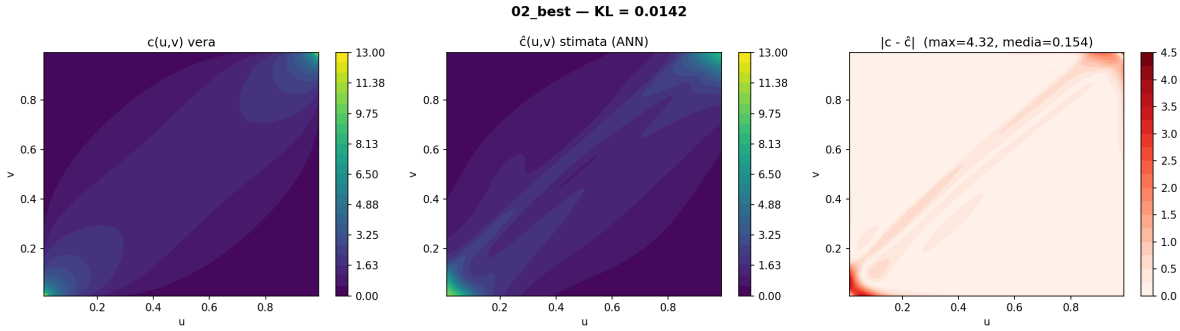

Figure 3: Best configuration: il pattern di errore è più strutturato (concentrato lungo la diagonale concordante), ma il massimo errore è sceso da 10.32 a 4.32. La rete sta modellando meglio i picchi.

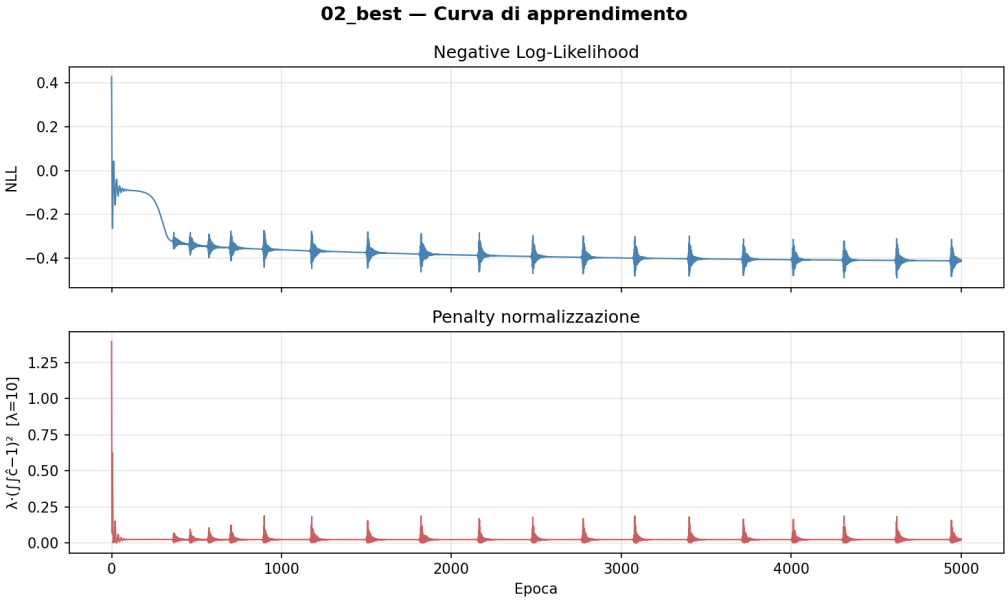

Figure 4: Curva di apprendimento — best configuration. La NLL converge molto più rapidamente (raggiunge -0.35 entro 500 epoche vs. 2500 per la naive) e scende più in basso (-0.41 vs. -0.31). Il penalty oscilla intorno a 0.02, coerente con $\iint \hat{c} \approx 1.047$.

6 Prossimi passi

1. **Copula non banale:** testare su una copula con struttura di dipendenza diversa (es. Clayton, Gumbel) per verificare la generalizzazione dell'approccio.

2. **Dataset reale:** applicare la pipeline a dati reali bivariati (es. ritorni finanziari) dove la vera copula è ignota.

3. **Confronto con baseline:** KDE bivariata e Gaussian Mixture Models sugli stessi dati, confrontando tramite cross-validation likelihood.