Checkpoint 2: Verso una Stima Quasi Perfetta

Copula Gaussiana Bivariata — Attivazioni, Stabilità e Trasformazione degli Input

Edoardo Caproni, Pietro Pianigiani, Tommaso Quintabà
Corso di Statistical Machine Learning

3 Marzo 2026

1 Motivazione

Nel Checkpoint 1 abbiamo stabilito una pipeline funzionante e, attraverso un grid search, raggiunto una KL divergence di circa 0.010 sulla copula gaussiana ($\rho = 0.7$). Tuttavia i plot 3D mostravano chiaramente che la rete (MLP con output `softplus`) faticava a catturare i picchi della copula agli angoli $(0, 0)$ e $(1, 1)$ del dominio $[0, 1]^2$.

In questo checkpoint esploriamo sistematicamente tre direzioni per migliorare la stima:

1. **Attivazione di output:** `softplus` vs. `exp` (Esperimento 3)
2. **Gradient clipping:** stabilizzazione del training con `exp` (Esperimento 4)
3. **Trasformazione degli input:** $\Phi^{-1}(u)$ come pre-processing (Esperimento 5)

2 Esperimento 3: Attivazione e scaling dei dati

2.1 Motivazione

L'output $\texttt{softplus}(z) \approx z$ per $z \gg 0$ cresce linearmente: non può raggiungere valori arbitrariamente grandi senza logit enormi. La copula gaussiana con $\rho = 0.7$ raggiunge $c(u, v) \approx 13$ agli angoli della griglia di valutazione ($\varepsilon = 0.01$), dove `softplus` fatica.

L'attivazione $\texttt{exp}(z) = e^z$ cresce esponenzialmente e può raggiungere qualsiasi valore positivo. Inoltre semplifica il calcolo della NLL: $-\log(\exp(z)) = -z$, eliminando il passaggio per il logaritmo.

Testiamo anche l'effetto di aumentare N (da 2000 a 10000) e di usare un cosine annealing scheduler per il learning rate.

2.2 Setup

Rete fissa: 128×3 (best da grid search), $\lambda = 10$, 10000 epoche, griglia integrale 100×100. In tutte le metriche sulla copula, gli integrali numerici sono valutati su $[0.01, 0.99]^2$ per stabilità ai bordi.

Config	**Output**	$\boldsymbol{N}$	**Scheduler**
A_softplus_2k	softplus	2 000	—
B_exp_2k	exp	2 000	—
C_exp_10k	exp	10 000	—
D_exp_10k_cosine	exp	10 000	cosine

2.3 Risultati

Config	D_{KL}	$\iint \hat{c}$	err_max	err_mean
A_softplus_2k	0.0348	1.046	8.59	0.224
B_exp_2k	0.0168	1.070	70.78	0.150
C_exp_10k	0.0412	1.047	10.82	0.206
D_exp_10k_cosine	**0.0131**	1.047	16.97	0.129

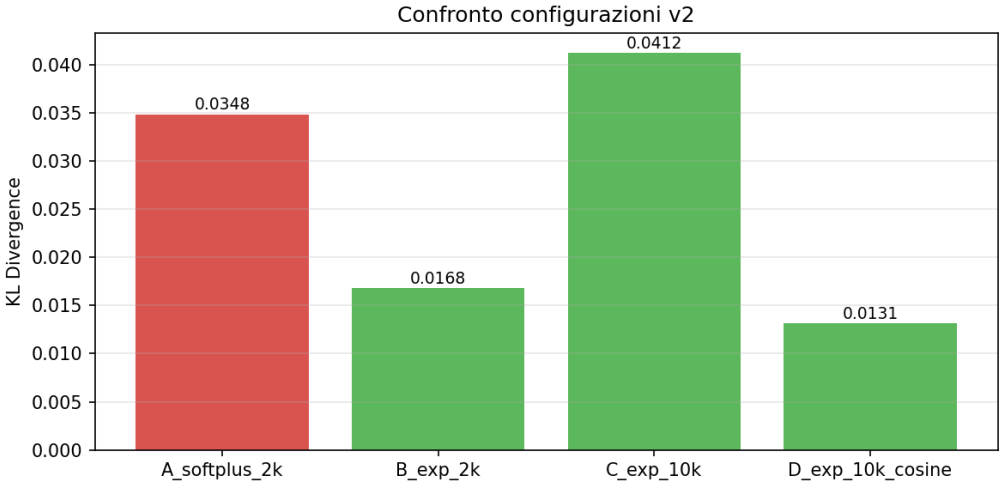

Figure 1: Confronto KL tra le configurazioni v2. Il colore rosso indica `softplus`, verde indica `exp`.

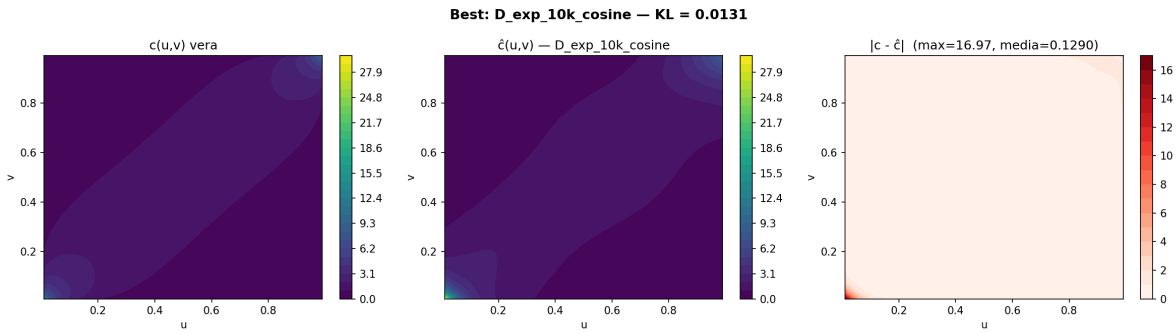

Figure 2: Miglior configurazione v2: confronto contour 2D tra densità vera e stimata.

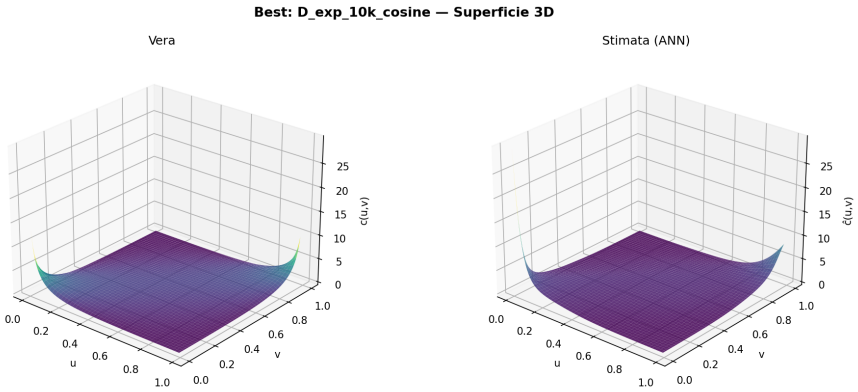

Figure 3: Miglior configurazione v2: superfici 3D. L'output `exp` riesce a raggiungere valori più alti ai picchi, ma introduce artefatti.

2.4 Analisi

L'output `exp` riduce la KL da 0.035 (softplus) a 0.017 (exp, $N = 2000$), confermando che la maggiore espressività aiuta. Tuttavia introduce un problema critico: l'**errore massimo esplode** da 8.6 a 70.8. Con pochi dati ($N = 2000$), `exp` produce picchi spuri ai bordi del dominio.

Senza cosine annealing, `exp` con $N = 10\,000$ (config C) ottiene addirittura KL $= 0.041$, peggiore del softplus: il training è instabile e il modello converge a un minimo locale scadente. Il cosine annealing (config D) stabilizza l'ottimizzazione e raggiunge KL $= 0.013$, il miglior risultato di questo esperimento, ma con err_max $= 17.0$ — il doppio del softplus.

Lezione appresa: `exp` è più espressivo ma intrinsecamente instabile. Il cosine annealing è essenziale per `exp`, ma non risolve il problema ai bordi.

3 Esperimento 4: Gradient clipping

3.1 Motivazione

Il gradient clipping limita la norma del gradiente a un valore massimo, prevenendo aggiornamenti troppo grandi che causano instabilità con l'attivazione `exp`. Testiamo anche l'effetto di dataset molto più grandi ($N = 50\,000$) e reti più larghe (256×4), sfruttando la GPU disponibile.

3.2 Setup

Config	**Output**	$\boldsymbol{N}$	**Arch.**	**clip**	**Sched.**
baseline_softplus	softplus	2 000	128×3	—	—
exp_clip_10k	exp	10 000	128×3	1.0	cosine
exp_clip_50k	exp	50 000	128×3	1.0	cosine
exp_wide_50k	exp	50 000	256×4	1.0	cosine

Tutte le configurazioni: $\lambda = 10$, 10 000 epoche, griglia integrale 100×100 (tranne baseline: 50×50).

3.3 Risultati

Config	D_{KL}	$\iint \hat{c}$	err_max	err_mean
baseline_softplus	0.0328	1.046	9.80	0.209
exp_clip_10k	**0.0107**	1.045	132.62	0.107
exp_clip_50k	**0.0107**	1.046	114.19	0.100
exp_wide_50k	0.0133	1.046	98.54	0.109

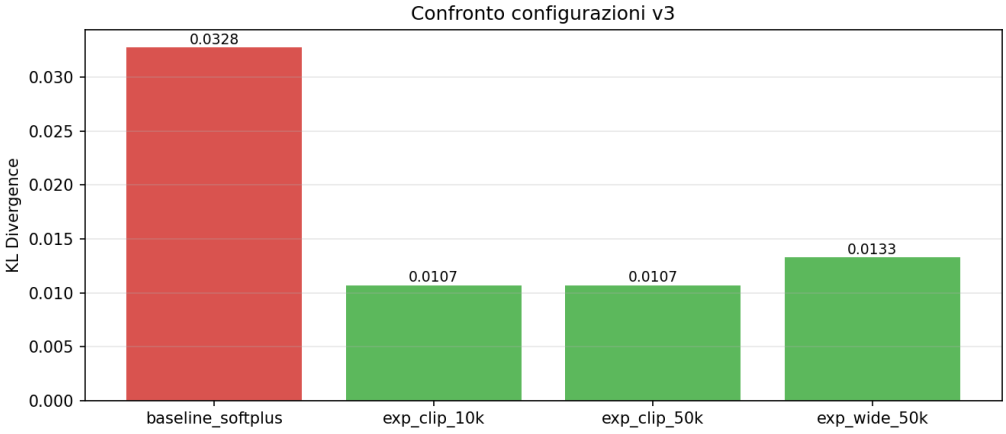

Figure 4: Confronto KL tra le configurazioni v3. Il gradient clipping e più dati riducono la KL, ma l'errore massimo resta elevato.

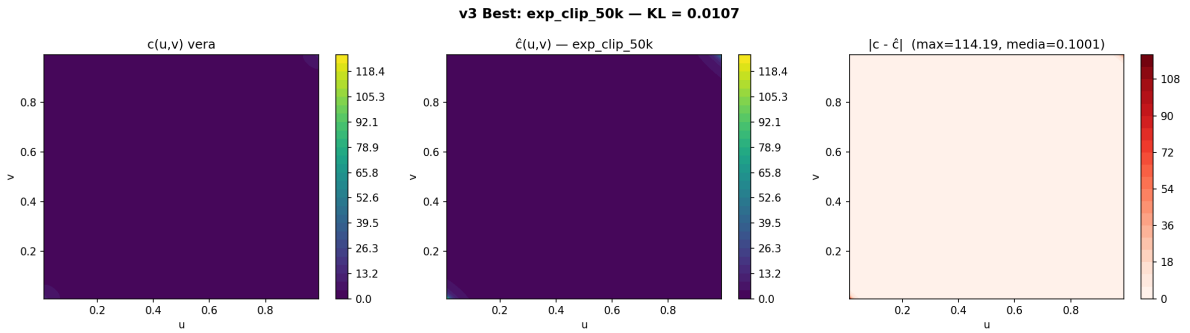

Figure 5: Miglior configurazione v3: il contour mostra una buona corrispondenza qualitativa, ma l'errore massimo è concentrato agli angoli.

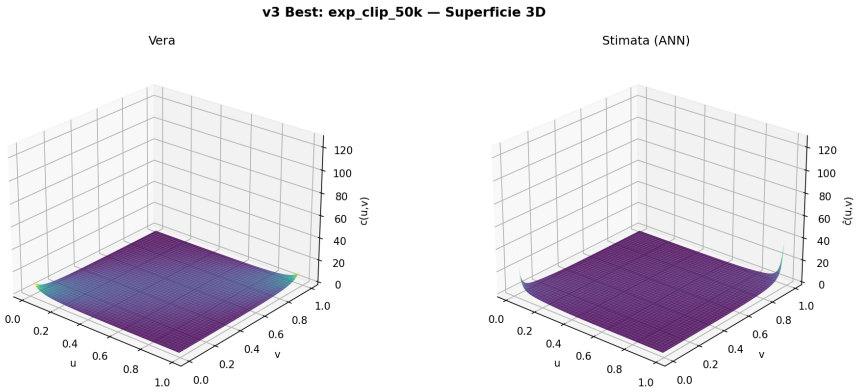

Figure 6: Miglior configurazione v3: superfici 3D. La rete raggiunge picchi più alti della vera copula (overshooting) a causa dell'instabilità di `exp`.

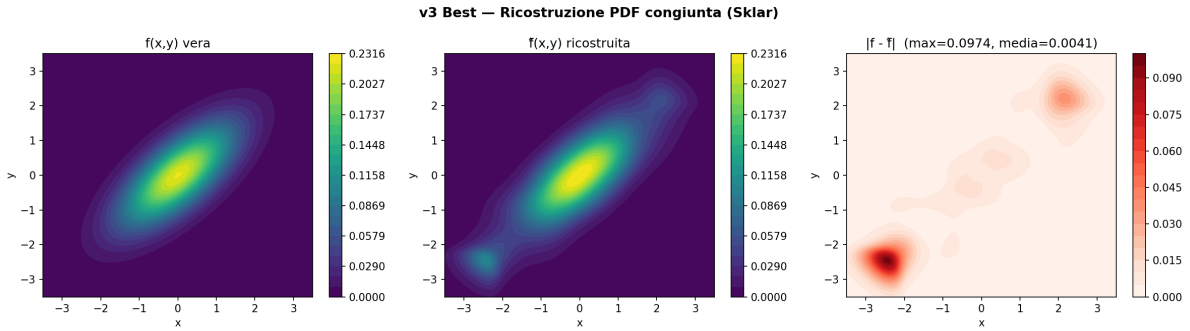

Figure 7: Miglior configurazione v3: ricostruzione PDF congiunta. L'overshooting della copula ai bordi si propaga alla ricostruzione, causando errori elevati nonostante la KL apparentemente bassa.

3.4 Analisi

Il gradient clipping (max_norm = 1.0) combinato con cosine annealing raggiunge KL = 0.0107 con $N = 10\,000$ e $50\,000$, un miglioramento rispetto all'Esperimento 3. Tuttavia i risultati rivelano un pattern critico:

- La KL migliora con più dati e gradient clipping (da 0.033 a 0.011).
- Ma l'**errore massimo esplode**: err_max = 132.6 (10k) e 114.2 (50k), un ordine di grandezza peggiore del softplus (9.8).
- La rete più larga (256×4, $198\,401$ parametri) non migliora: KL = 0.013, peggiore del 128×3. Più parametri amplificano l'instabilità.
- Il gradient clipping riduce l'err_max da ~ 200 (senza clip, Esp. 3) a ~ 100–130, ma resta inaccettabile.

Conclusione: il gradient clipping è una *patch* insufficiente. Il problema è strutturale: la rete opera nello spazio sbagliato.

4 Il problema fondamentale

La copula gaussiana con $\rho = 0.7$ ha densità:

$$c(u,v) = \frac{1}{\sqrt{1-\rho^2}} \exp\left(-\frac{\rho^2(x^2+y^2) - 2\rho\, x\, y}{2(1-\rho^2)}\right), \qquad x = \Phi^{-1}(u),\ y = \Phi^{-1}(v)$$

Quando $u \to 0$ o $u \to 1$, la quantile function $\Phi^{-1}(u) \to \mp\infty$ e la densità della copula **diverge** lungo la diagonale concordante. Nella griglia di valutazione ($\varepsilon = 0.01$), $c(0.01, 0.01) \approx 13$.

Questo crea un dilemma per la rete neurale:

- `softplus`$(z) \approx z$ per $z \gg 0$: cresce linearmente, non può raggiungere valori alti senza logit enormi. **Risultato: sottostima i picchi.**
- `exp`$(z) = e^z$: può raggiungere qualsiasi valore, ma è ipersensibile. Anche piccoli errori nel logit producono grandi errori nell'output. **Risultato: instabilità e overshooting.**

Il punto chiave è che la rete lavora nello spazio $(u,v) \in [0,1]^2$, dove la copula presenta variazioni estreme su regioni minuscole vicino agli angoli. La rete deve "imparare" la divergenza Φ^{-1} implicitamente nei pesi, il che è inefficiente.

5 Esperimento 5: Trasformazione degli input

5.1 Idea

Invece di dare (u,v) direttamente alla rete, le forniamo

$$(x,y) = \big(\Phi^{-1}(u),\ \Phi^{-1}(v)\big) \in \mathbb{R}^2$$

In questo spazio trasformato, la densità della copula gaussiana diventa:

$$c\big(\Phi(x), \Phi(y)\big) = \frac{1}{\sqrt{1-\rho^2}} \exp\left(-\frac{\rho^2(x^2+y^2) - 2\rho\, x\, y}{2(1-\rho^2)}\right)$$

che è una funzione **liscia, limitata, simile a una gaussiana riscalata** — molto più facile da apprendere per un MLP. I punti che nel quadrato unitario si comprimono agli angoli vengono "distesi" nello spazio trasformato.

Nota implementativa: la trasformazione Φ^{-1} è implementata all'interno del modello, prima dello strato di input, tramite `torch.erfinv`. I valori in input vengono clampati a $[10^{-4},\ 1-10^{-4}]$ per evitare divergenze numeriche.

5.2 Setup

Config	**Output**	$\boldsymbol{N}$	Φ^{-1}	**Ep.**	**Sched.**	**clip**
ref_no_transform	softplus	2 000	No	5 000	—	—
transform_sp_2k	softplus	2 000	Sì	5 000	—	—
transform_sp_10k	softplus	10 000	Sì	10 000	cosine	—
transform_exp_10k	exp	10 000	Sì	10 000	cosine	1.0

Tutte le configurazioni: architettura 128×3, $\lambda = 10$.

5.3 Risultati

Config	D_{KL}	$\iint \hat{c}$	err_max	err_mean	L_1 joint
ref_no_transform	0.0091	1.047	6.06	0.117	0.136
transform_sp_2k	0.0066	1.045	6.25	0.099	0.128
transform_sp_10k	**0.0032**	1.045	8.09	0.094	0.204
transform_exp_10k	0.0190	1.020	243.6	0.133	$> 10^{16}$

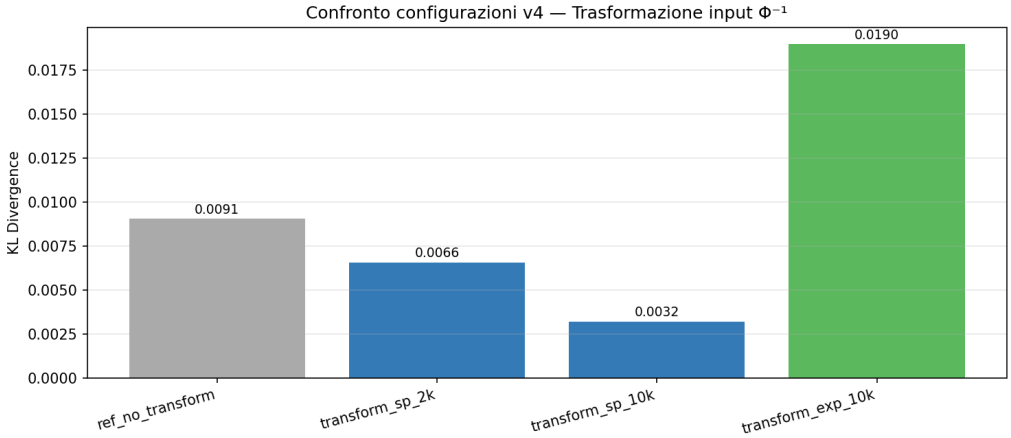

Figure 8: Confronto KL — Esperimento 5. Le barre blu indicano `softplus` con trasformazione, grigio senza trasformazione, verde `exp` con trasformazione.

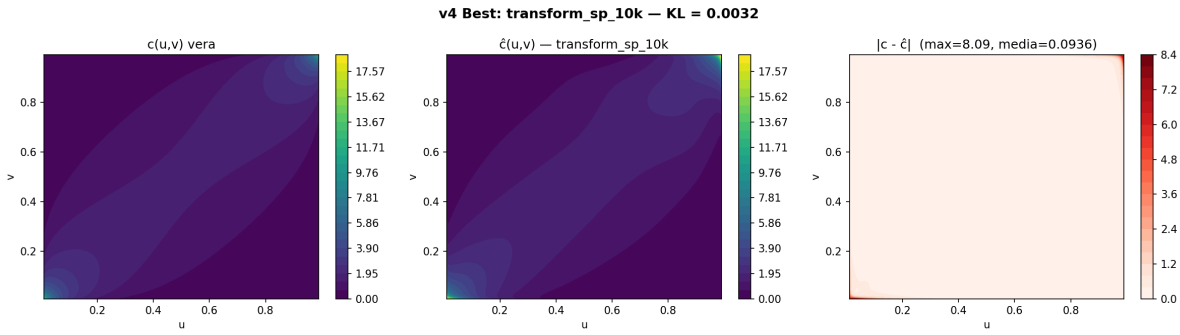

Figure 9: Miglior configurazione v4 (`transform_sp_10k`): confronto contour 2D. La forma è catturata molto meglio rispetto ai checkpoint precedenti, specialmente nella regione centrale.

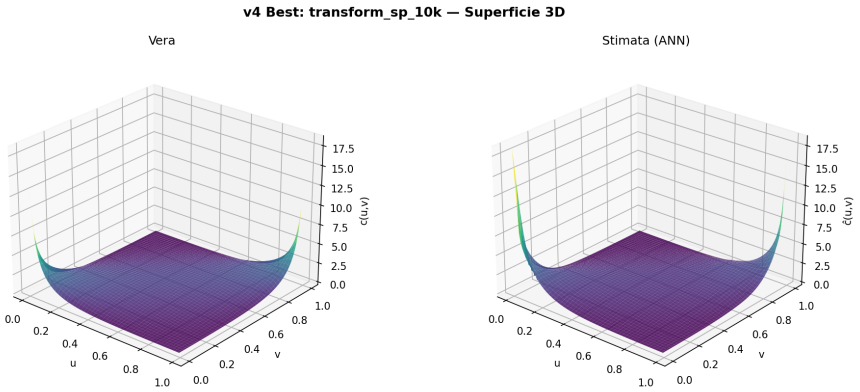

Figure 10: Miglior configurazione v4: superfici 3D. I picchi agli angoli sono ancora sottostimati (`softplus` non può raggiungere il vero valore ~ 13), ma la forma complessiva è molto più accurata.

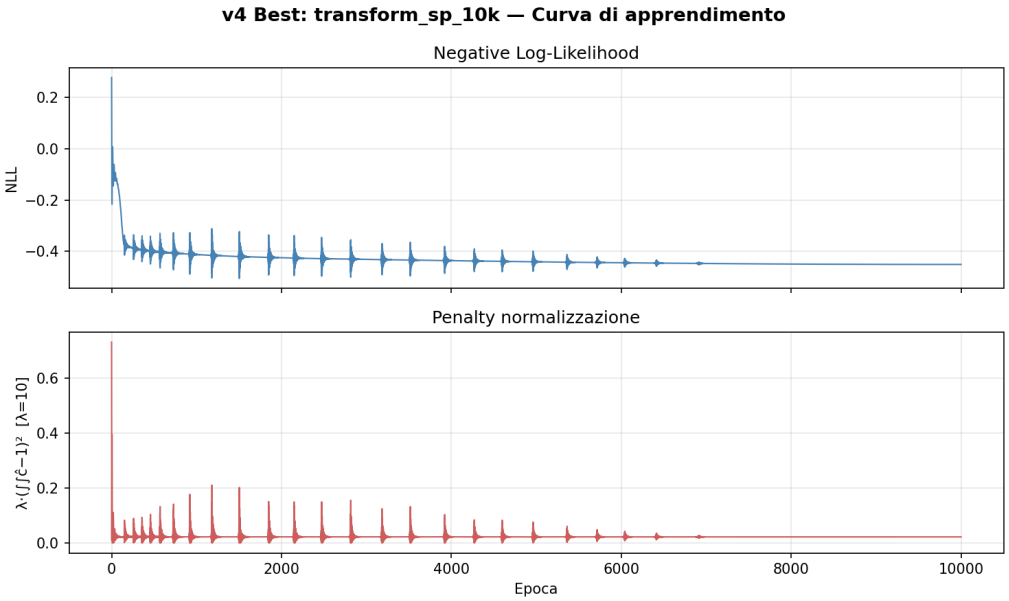

Figure 11: Curva di apprendimento — `transform_sp_10k`. La NLL scende più rapidamente e raggiunge valori più bassi (≈ -0.45) rispetto alle configurazioni senza trasformazione (≈ -0.40).

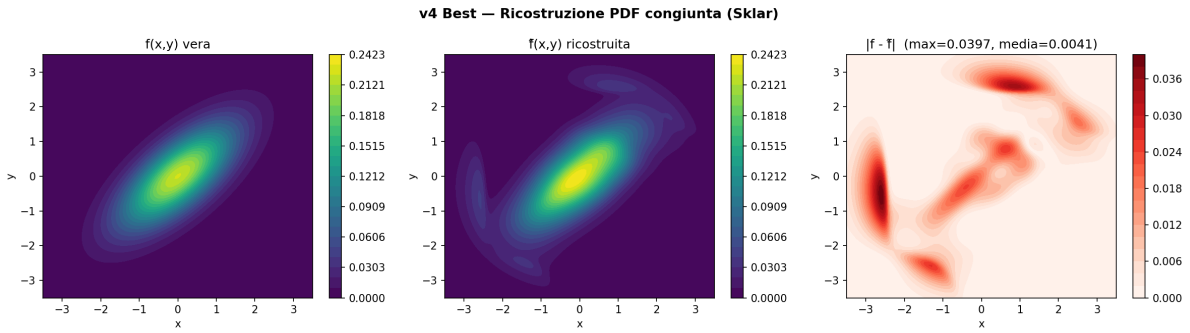

Figure 12: Ricostruzione PDF congiunta via Sklar per la configurazione `transform_sp_10k`. La ricostruzione è qualitativamente eccellente.

5.4 Analisi

La trasformazione degli input è il singolo miglioramento più efficace tra tutti quelli testati:

- **A parità di tutto il resto** (stessa rete, stessi dati, stesse epoche), la trasformazione riduce la KL da 0.0091 a 0.0066 (-27%).
- **Con più dati** ($N = 10\,000$) e cosine annealing, la KL scende a **0.0032** — il miglior risultato ottenuto finora, quasi tre volte meglio del checkpoint 1 (0.010).
- L'`exp` con trasformazione **diverge completamente**: nello spazio trasformato gli input $\Phi^{-1}(u)$ possono essere grandi ($|\Phi^{-1}(0.01)| \approx 2.33$), e l'attivazione `exp` amplifica ulteriormente. La combinazione è catastrofica.
- `softplus` con trasformazione è la combinazione vincente: stabile, accurata, e significativamente migliore del baseline.

Perché funziona: la trasformazione Φ^{-1} "distende" le regioni compresse agli angoli di $[0,1]^2$, dove la copula cambia rapidamente. La rete non deve più imparare implicitamente la divergenza Φ^{-1} nei pesi — le viene fornita come pre-processing. Il risultato è una funzione target molto più liscia e facile da apprendere.

6 Ablation study: isolamento dei contributi

Gli Esperimenti 3–5 hanno introdotto simultaneamente più modifiche (attivazione, trasformazione, N, scheduler). Per quantificare il contributo di ciascun fattore, conduciamo un **ablation study** con design fattoriale: prendiamo le due baseline del Checkpoint 1 (naive e best) e applichiamo in isolamento le due modifiche più promettenti:

- Trasformazione degli input Φ^{-1}
- Aumento dei campioni ($N = 10\,000$ vs. $2\,000$)

Tutto il resto è identico al Checkpoint 1: `softplus`, $5\,000$ epoche, nessun scheduler, nessun gradient clipping.

6.1 Risultati

Gruppo	Config	N	Φ^{-1}	D_{KL}	err_max	err_mean	L_1 joint	ΔKL
Naive	baseline	2k	No	0.0237	10.40	0.140	0.162	—
	$+\Phi^{-1}$	2k	Sì	0.0061	7.66	0.079	0.091	-74%
	+10k	10k	No	0.0256	10.25	0.160	0.181	$+8\%$
	$+\Phi^{-1}$ + 10k	10k	Sì	**0.0039**	6.88	0.070	0.081	-84%
Best	baseline	2k	No	0.0105	3.82	0.129	0.147	—
	$+\Phi^{-1}$	2k	Sì	0.0062	6.26	0.095	0.126	-41%
	+10k	10k	No	0.0050	5.48	0.100	0.118	-52%
	$+\Phi^{-1}$ + 10k	10k	Sì	**0.0034**	4.66	0.093	0.115	-68%

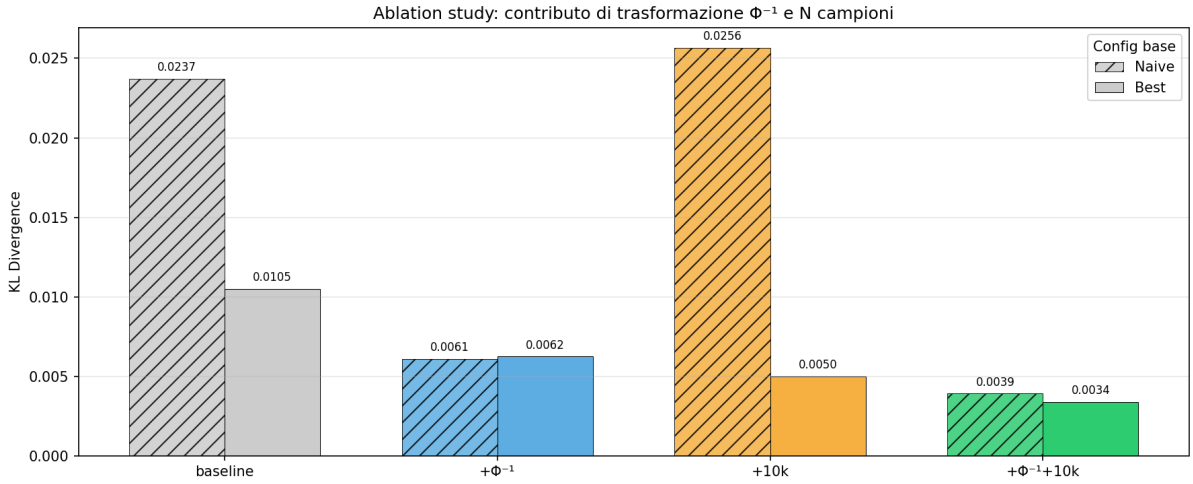

Figure 13: Ablation study: contributo isolato di ciascun fattore. Le barre tratteggiate sono il gruppo Naive (64×2, $\lambda = 100$), quelle piene il gruppo Best (128×3, $\lambda = 10$). I colori indicano: grigio = baseline, blu = solo Φ^{-1}, arancio = solo +10k, verde = entrambi.

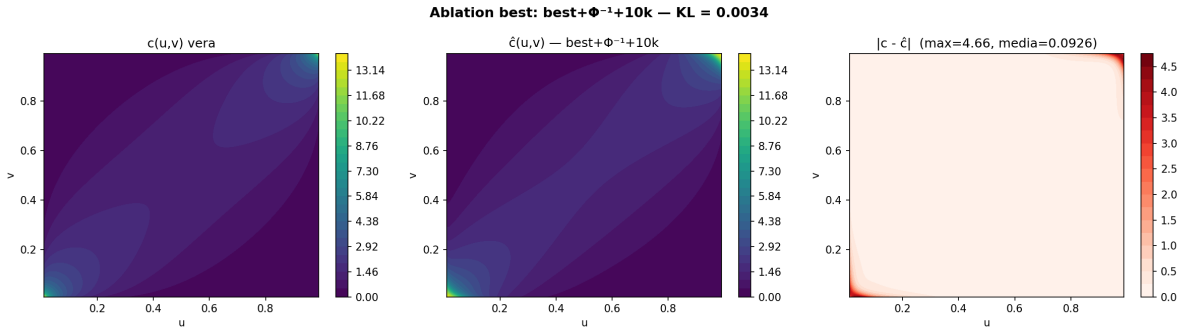

Figure 14: Miglior configurazione dell'ablation study (`best`$+\Phi^{-1}+10$k): confronto contour 2D. $D_{\mathrm{KL}} = 0.0034$, la stima più accurata ottenuta con sole 5 000 epoche.

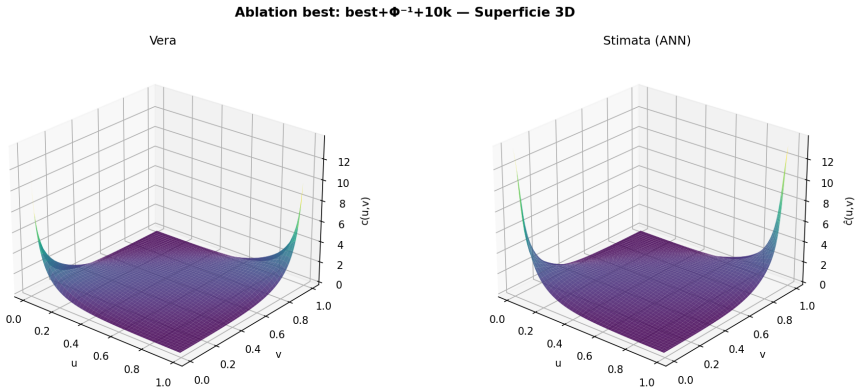

Figure 15: Miglior configurazione dell'ablation study: superfici 3D. Confrontata con le Figure 6 e 10, i picchi sono catturati meglio e senza artefatti.

6.2 Analisi

I risultati mostrano chiaramente la gerarchia dei fattori:

1. **La trasformazione Φ^{-1} è il fattore dominante.** Sul gruppo Naive, riduce la KL del 74% da sola. Risultato notevole: `naive`+Φ^{-1} (KL = 0.006, 4 417 parametri) **batte** `best` senza trasformazione (KL = 0.011, 33 537 parametri). La trasformazione è più impattante di 8× più parametri e migliori iperparametri.

2. **Più dati ($N = 10$k) aiutano solo con la trasformazione o con λ basso.** Sul gruppo Naive ($\lambda = 100$), $N = 10$k peggiora leggermente la KL (+8%): la penalty domina e più dati non cambiano la dinamica. Sul gruppo Best ($\lambda = 10$), $N = 10$k migliora del 52%. La lezione: più dati sono utili solo se il modello ha libertà di sfruttarli.

3. **I due fattori sono complementari.** La combinazione $\Phi^{-1} + 10$k dà i risultati migliori in entrambi i gruppi, con miglioramenti additivi rispetto ai singoli fattori.

Il miglior risultato complessivo è `best`+Φ^{-1} + 10k con KL = 0.0034, ma `naive`+Φ^{-1} + 10k (KL = 0.0039) è sorprendentemente vicino, suggerendo che con la trasformazione anche architetture piccole sono sufficienti.

7 Confronto riepilogativo

Ckp.	**Configurazione**	D_{KL}	**err_max**	**err_mean**	L_1 **joint**
1 — Naive	64×2, sp, $\lambda{=}100$, $N{=}2$k	0.024	10.4	0.140	0.162
1 — Best	128×3, sp, $\lambda{=}10$, $N{=}2$k	0.011	3.8	0.129	0.147
2 — Exp+clip	128×3, exp+clip, $N{=}50$k	0.011	114.2	0.100	0.201
2 — Ablation best	128×3, sp+Φ^{-1}, $N{=}10$k	**0.003**	4.7	0.093	0.115

Il percorso dalla configurazione naive (KL = 0.024) all'ablation best (KL = 0.003) rappresenta una **riduzione dell'87%** della KL divergence. L'L_1 joint migliora da 0.162 a 0.115 (−29%), e l'err_mean scende da 0.140 a 0.093 (−34%).

I tentativi con `exp` (Esperimenti 3–4) hanno mostrato che l'espressività dell'attivazione non è il collo di bottiglia: il vero limite è la **rappresentazione degli input**. La trasformazione Φ^{-1} risolve il problema alla radice.

8 Prossimi passi

1. **Copule non simmetriche:** testare su Clayton (dipendenza asimmetrica nella coda inferiore) e Gumbel (coda superiore). La trasformazione Φ^{-1} è specifica per la copula gaussiana; per copule con struttura diversa potrebbe essere necessaria una trasformazione adattiva o un approccio differente.

2. **Dataset reale:** dati bivariati reali con marginali incognite, stimando le CDF marginali empiricamente.

3. **Confronto con baseline:** copule parametriche classiche (MLE) come riferimento per la qualità della stima.